

Relazione del primo progetto di Big Data Security by design nei datalake

Il progetto consiste nell'implementare la cybersecurity all'interno del datalake, realizzando una piattaforma big data end-to-end per l'analisi del traffico di rete. Per rendere la simulazione più realistica, tutto ciò è stato implementato su Kathara, che simula una rete grazie alla containerizzazione, usando il software Docker. Eseguendo ciò, ogni dispositivo IS o ES corrisponde ad un container Docker. Perciò, l'architettura big data implementata è situata su un data center di tipo fat-tree.

La rete è divisa in tre AS, dove:

- AS1 è situata la macchina del presunto hacker;
- AS2 è dove è situato il data-center e l'admin che gestisce l'architettura;
- AS3 è situata la risoluzione dei nomi.




Figura 1: Topologia della rete

Per quanto riguarda, l'architettura, sono stati implementati:

- Spark come motore per l'elaborazione distribuita;
- MongoDB come data-lake operativo;
- LLM locali per l'assistente AI, grazie l'uso di Ollama.

Di seguito, verrà spiegata nel dettaglio ogni componente dell'architettura, motivando le scelte implementative.

1 Dataset di riferimento

Il dataset BigFlow-NIDS, recuperato da Kaggle, contiene flussi di traffico etichettati per il rilevamento delle intrusioni di rete (NIDS). Contiene oltre 66.355.798 record suddivisi tra traffico legittimo (Benign) e diverse categorie di attacco (DDoS, Brute Force, ecc.). Il dataset viene convertito da CSV a Apache Parquet tramite Spark al primo avvio, poiché quest'ultimo garantisce:

- compressione colonnare, che struttura i dati per colonna invece che per riga, riducendo lo spazio occupato e velocizzando la ricerca;
- schema-on-read, cioè un metodo di gestione di dati che salva le informazioni grezze senza una struttura fissa e lo schema viene applicato solo quando i dati vengono letti;
- compatibilità nativa con Spark-SQL.

Link repository: https://github.com/andymacale/primo_progetto_big_data